Лекция 7. Natural Language Processing. Word embeddings.

Глубинное обучение

Антон Кленицкий

Задачи NLP

Задачи NLP

Text classification

- Сопоставляем метки всему тексту как целому
- Sentiment analysis - анализ тональности (положительная, нейтральная, отрицательная)
- Spam / not spam

Word-level classification

- Сопоставляем метки каждому слову по отдельности
- Part-of-speech (POS) tagging - частеречная разметка
- Named Entity Recognition (NER) - распознавание именованных сущностей (person, location, organization, date,...)

Задачи NLP

- Machine translation
- Text summarization (extractive / abstractive)
- Question Answering
- Dialogue systems
- Text generation

Word embeddings

Представление текста

Первый шаг - токенизация (разбиение текста на отдельные слова - токены)

Дальше нужно перевести слова в числовой вид

Представление текста

Первый шаг - токенизация (разбиение текста на отдельные слова - токены)

Дальше нужно перевести слова в числовой вид

Самый простой вариант - one-hot encoding

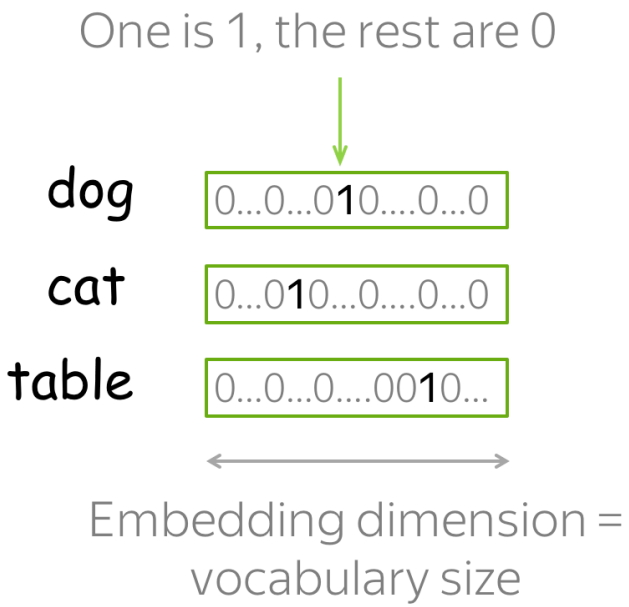

Image credit

One-hot encoding

Минусы one-hot encoding

- Большой словарь -> очень большая размерность
- Не учитывает смысл и взаимоотношения между словами (все вектора ортогональны друг другу)

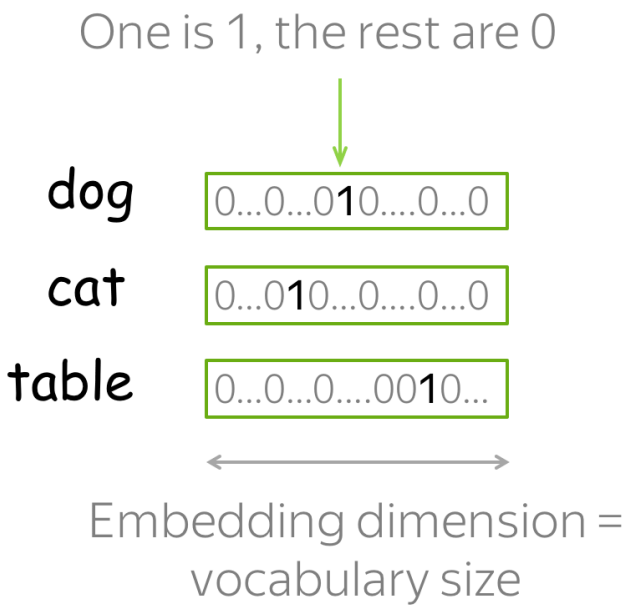

Image credit

Word embeddings

Хотим представить слова в виде векторов небольшой размерности, которые отражают их смысл, чтобы

- Близкие по смыслу слова имели похожие вектора
- Разные по смыслу слова имели непохожие вектора

Основная идея:

Слова, которые часто встречаются в схожих контекстах, имеют похожее значение (distributional hypothesis)

Word2Vec

Общая идея:

- Вектора слов, которые встречаются в одном контексте, должны быть близки

Реализация

- Учимся предсказывать контекст (окружающие слова) по вектору данного слова

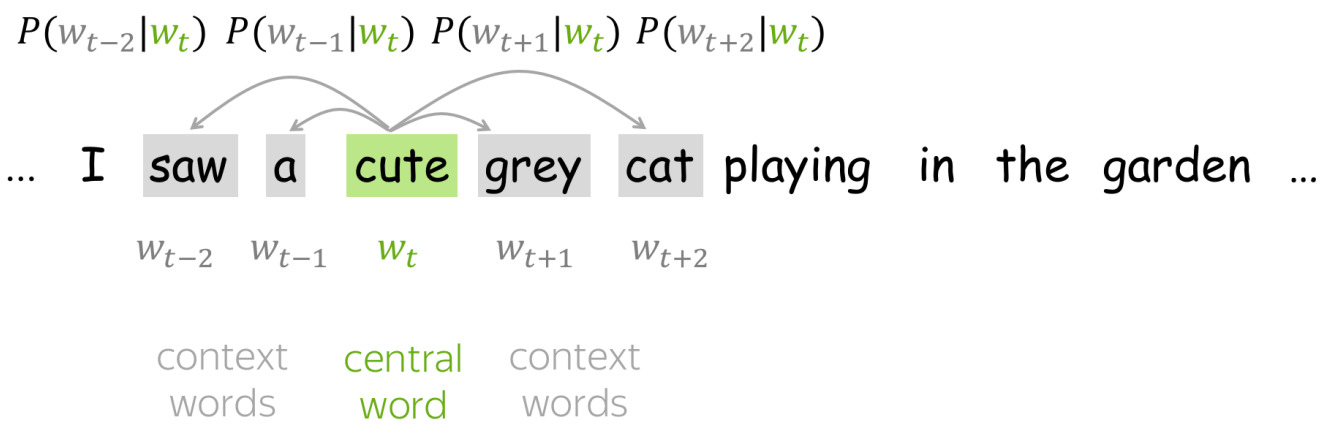

Image credit

Word2Vec

- Берем большой корпус текстов
- Проходим по текстам скользящим окном, смещаемся на одно слово на каждом шаге
- В каждом окне есть центральное слово слова контекста (остальные слова в окне)
- Предсказываем вероятность окружающих слов основе вектора центрального слова)

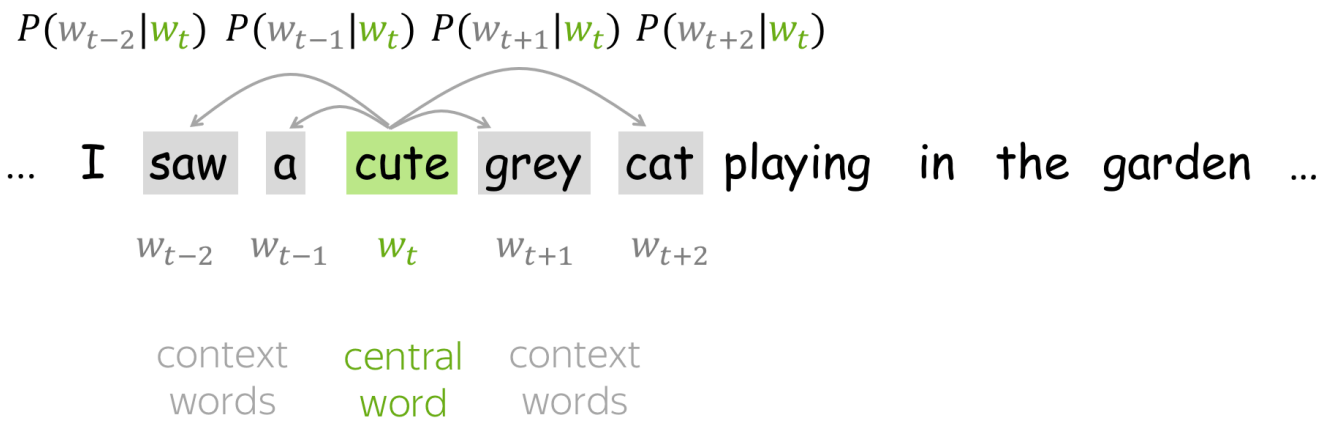

Image credit

Word2Vec

- Берем большой корпус текстов
- Проходим по текстам скользящим окном, смещаемся на одно слово на каждом шаге
- В каждом окне есть центральное слово и слова контекста - остальные слова в окне
- Предсказываем вероятность окружающих слов на основе вектора центрального слова

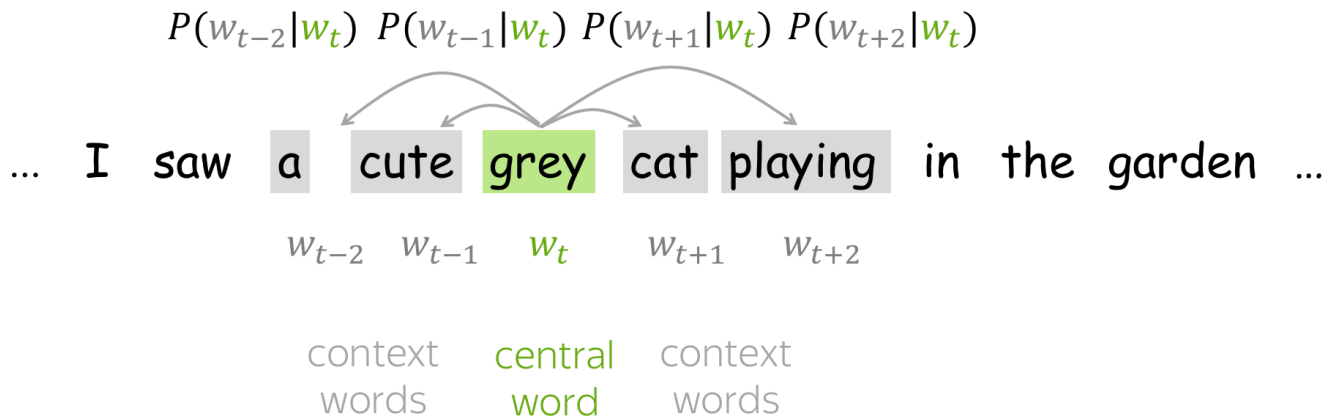

Image credit

Word2Vec

Функция потерь - negative log-likelihood:

$$L(\theta) = -\frac{1}{T}\sum_{t=1}^{T}\sum_{-m\leq j\leq m, j\neq 0} \log P(w_{t+j}|w_t, \theta)$$

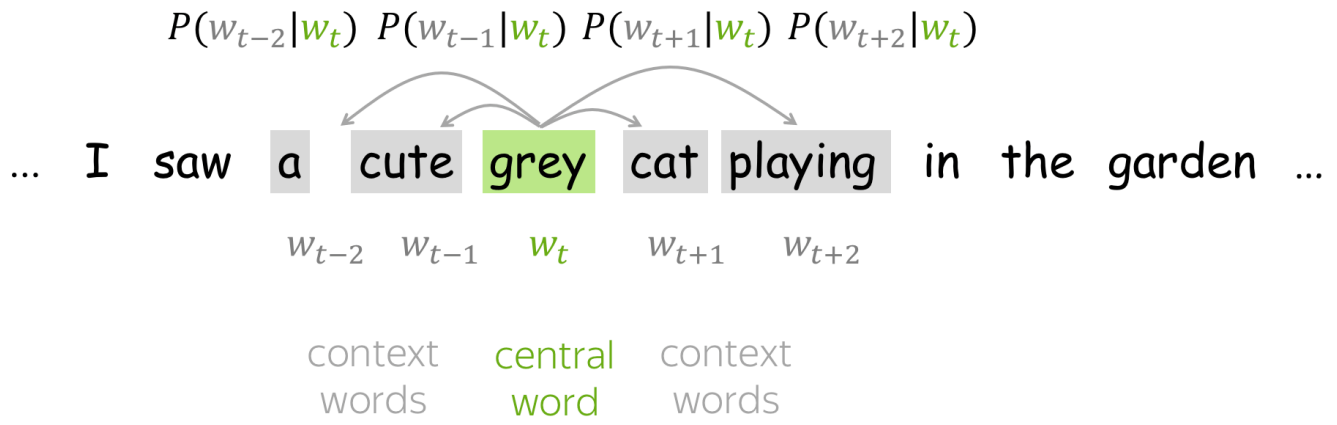

Image credit

Word2Vec

Для каждого слова обучаются два вектора - v_w когда слово в центре и u_w когда слово в контексте.

$$P(o|c) = \frac{\exp(u_o^T v_c)}{\sum_{w \in V} \exp(u_w^T v_c)}$$

o - outside word, c - central word

Обучаем стохастическим градиентым спуском:

$$L_{t,j}(\theta) = -\log P(o|c) = -u_o^T v_c + \log \sum_{w \in V} \exp(u_w^T v_c)$$

$$v_c = v_c - \alpha \frac{\partial L_{t,j}(\theta)}{\partial v_c}$$

$$u_w = u_w - \alpha \frac{\partial L_{t,j}(\theta)}{\partial u_w}$$

Увеличиваем близость между v_c и u_o и уменьшаем близость между v_c и всеми остальными u_w.

Negative sampling

$$L_{t,j}(\theta) = -\log P(o|c) = -u_o^T v_c + \log \sum_{w \in V} \exp(u_w^T v_c)$$

Словарь очень большой, на каждом шаге SGD обновляем вектора всех слов u_w - долго.

Negative sampling

$$L_{t,j}(\theta) = -\log P(o|c) = -u_o^T v_c + \log \sum_{w \in V} \exp(u_w^T v_c)$$

Словарь очень большой, на каждом шаге SGD обновляем вектора всех слов u_w - долго.

Выход - сэмплирование отрицательных примеров

$$\sum_{w \in V} \exp(u_w^T v_c) \to \sum_{w \in \{w_{i_1}, .., w_{i_K}\}} \exp(u_w^T v_c)$$

CBOW vs Skip-Gram

- Skip-gram - предсказание контекста по центральному слову
- CBOW (Continuous Bag-of-Words) - предсказание центрального слова по контексту

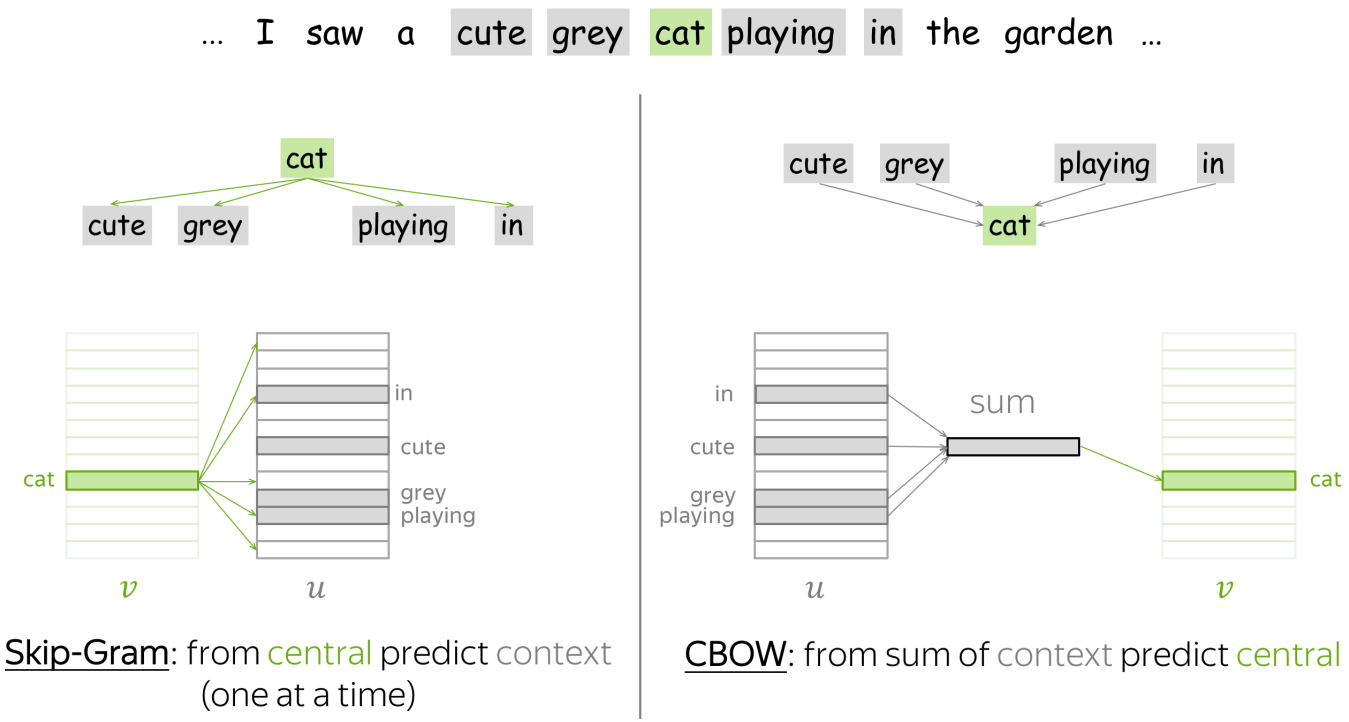

Image credit

Соотношения между эмбеддингами

semantic: $v(\text{king}) - v(\text{man}) + v(\text{woman}) \approx v(\text{queen})$

syntactic: $v(\text{kings}) - v(\text{king}) + v(\text{queen}) \approx v(\text{queens})$

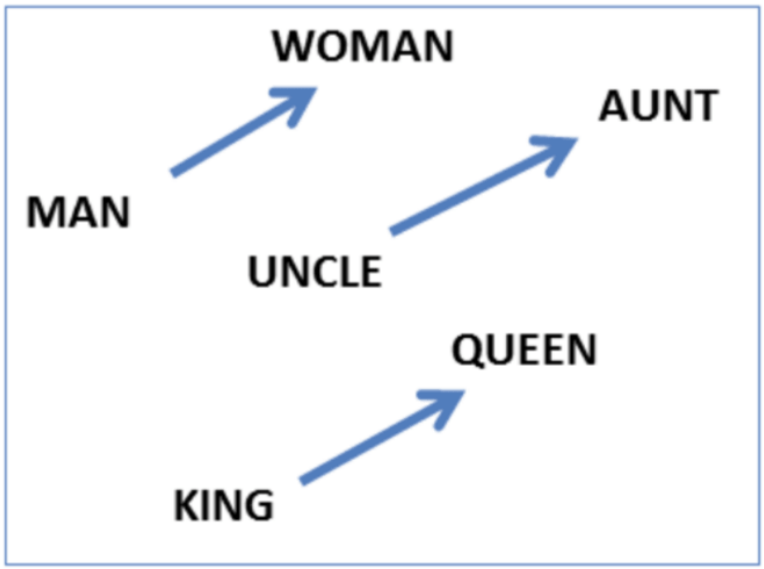

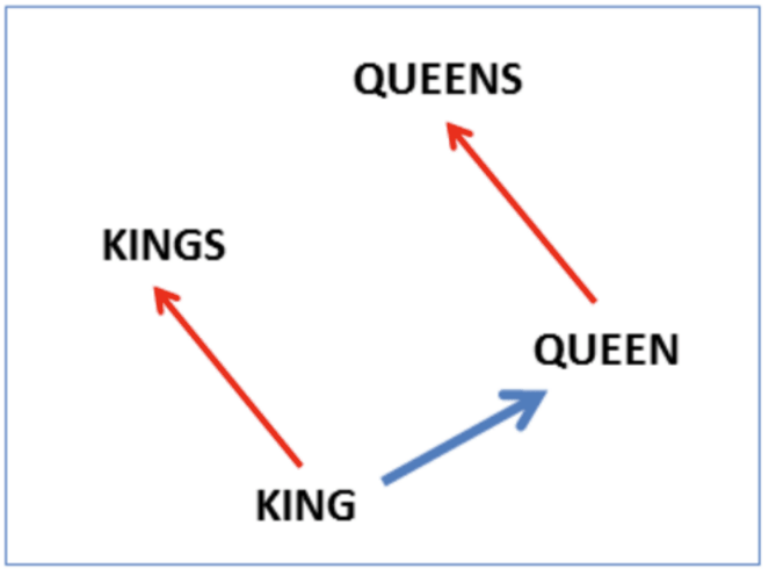

Соотношения между эмбеддингами

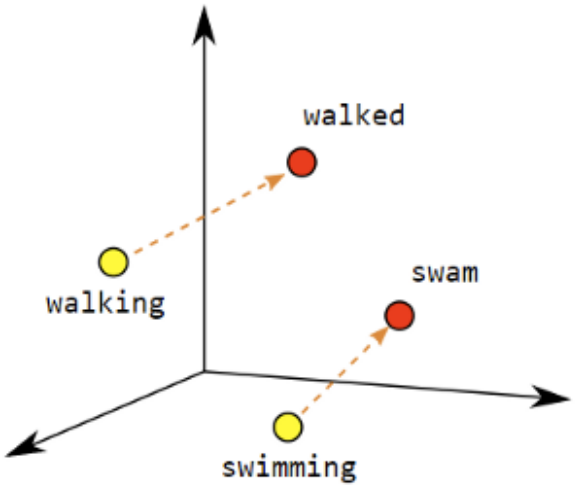

Verb Tense

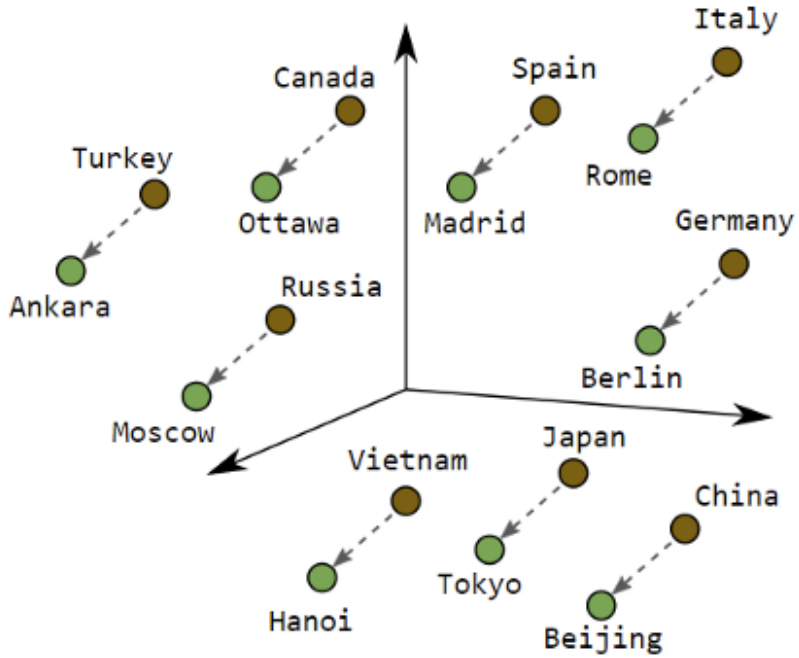

Country-Capital

Global Vectors (GloVe)

Обучение на основе глобальных статистик совместных встречаемостей слов, посчитанных по всему корпусу текстов

context vector

word vector

bias terms (also learned)

$$J(\theta) = \sum_{w,c \in V} f(\mathrm{N}(w, c)) \cdot (u_c^T v_w + b_c + \overline{b_w} - \log \mathrm{N}(w, c))^2$$

Weighting function to:

- penalize rare events
- not to over-weight frequent events

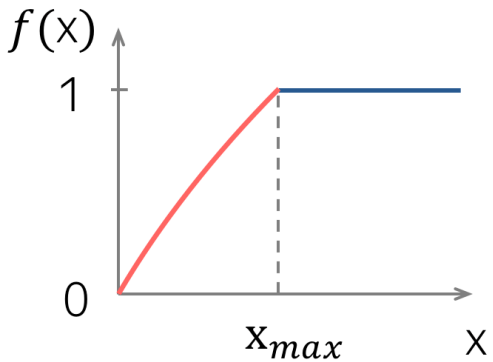

$$\begin{cases} (x/x_{max})^{\alpha} & \text{if } x < x_{max}, \\ 1 & \text{otherwise.} \end{cases}$$

$\alpha = 0.75, x_{max} = 100$

Image credit

Out-of-vocabulary words

Обучились с фиксированным словарем.

Что делать, если появилось новое слово?

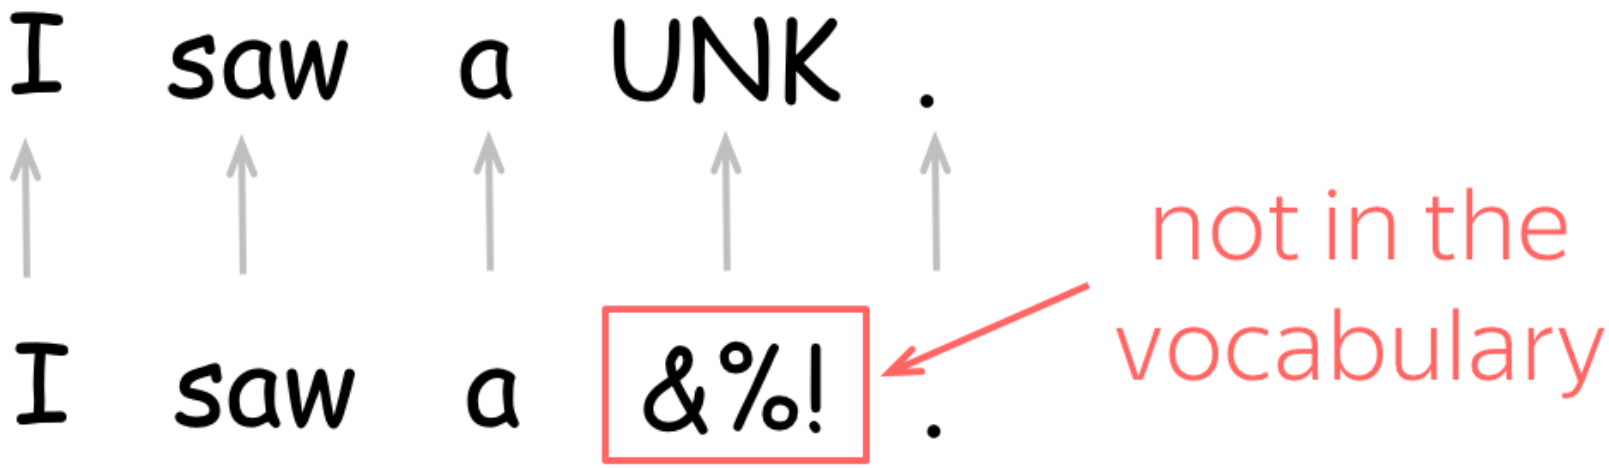

Image credit

FastText

Идея - считать вектора по n-граммам, составляющим данное слово.

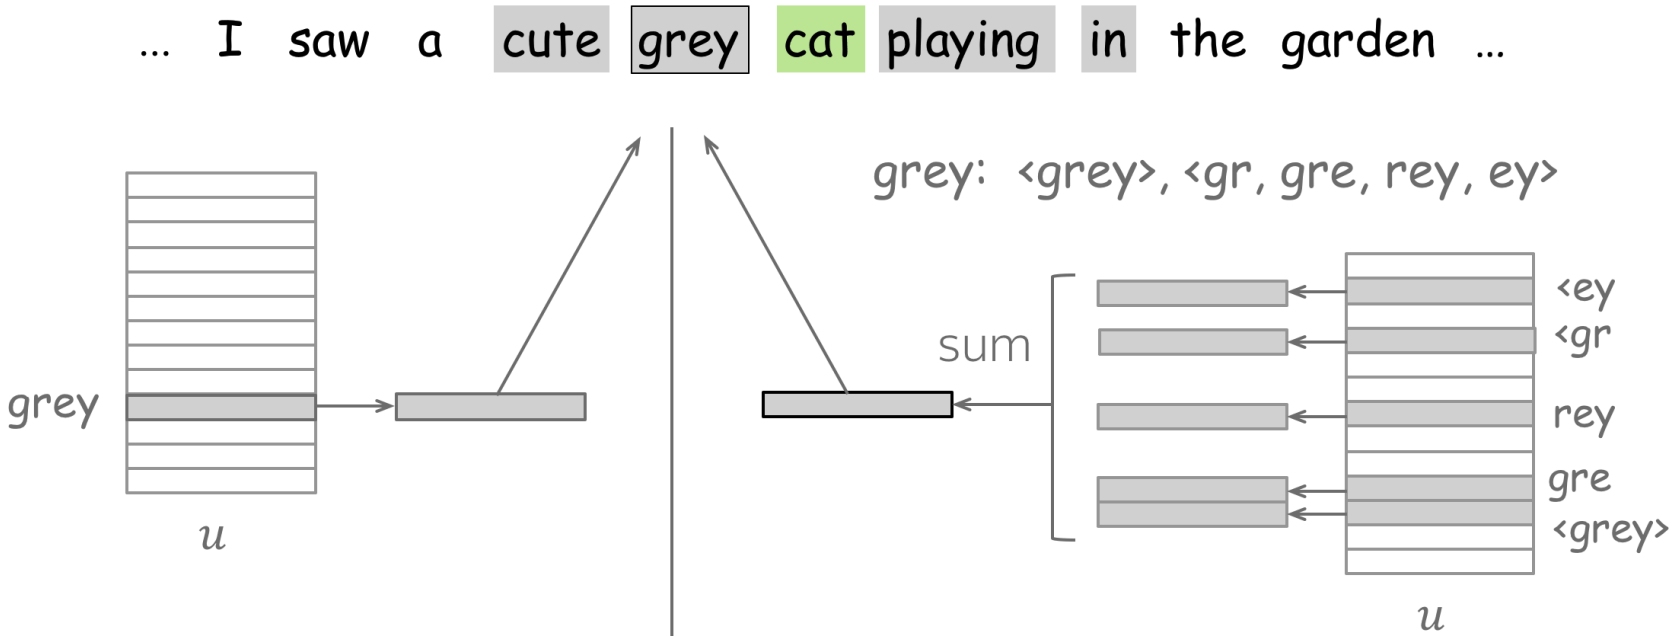

Image credit

Для любого слова можно получить какое-то представление.

Anything2Vec

Идею представления объектов в виде эмбеддингов можно расширить на самые разные данные

Word embeddings + нейросети

Общая схема

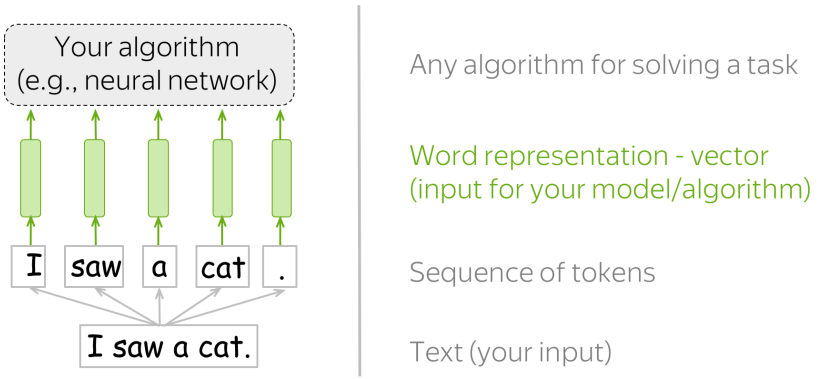

Image credit

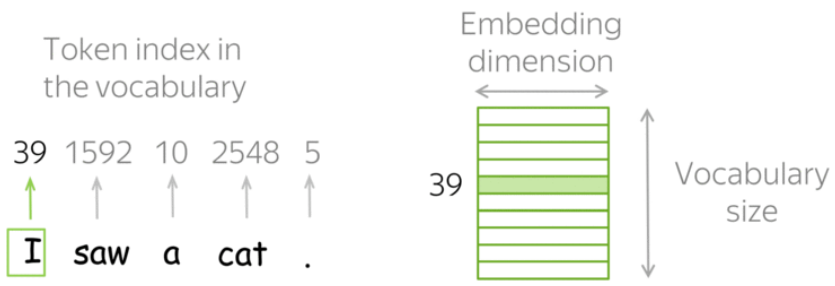

Image credit

Общая схема

Берем обученные на большом корпусе текстов эмбеддинги, используем в своей задаче

Freeze

- Замораживаем эмбеддинги, учим только другие слои

Finetune

- Инициализируем слой эмбеддингов, потом дообучаем этот слой вместе с остальными слоями

По сути это пример transfer learning

1D CNN

- Слой эмбеддингов
- 1D свертки с разными kernel size
- Global pooling
- fully connected layers

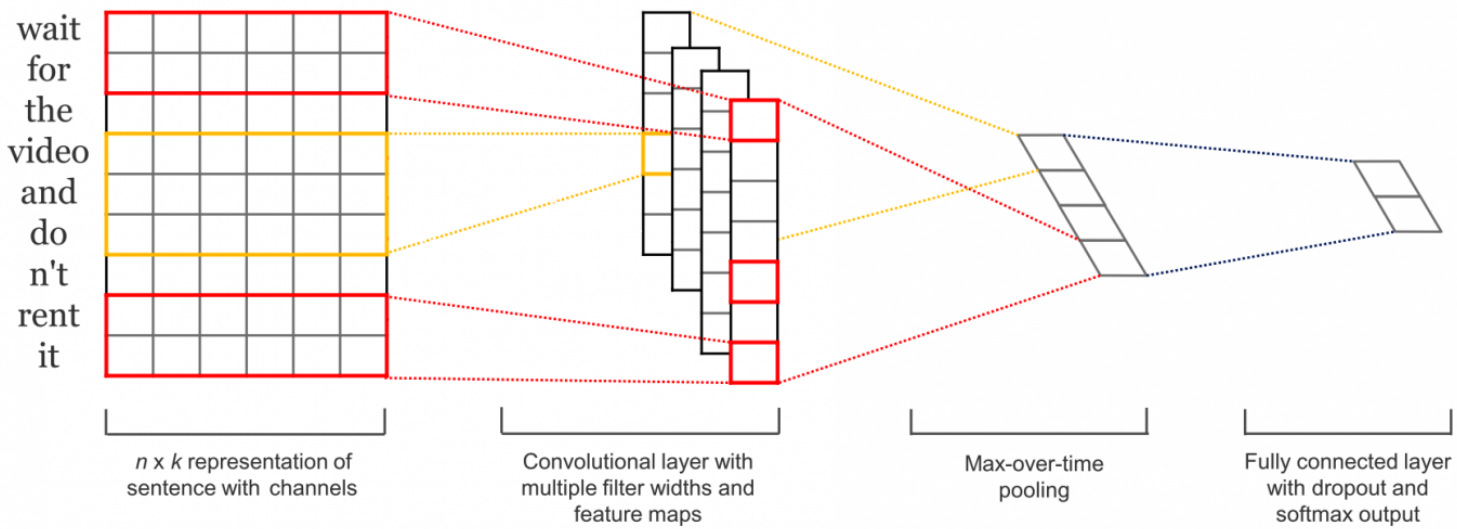

Image credit

Subword tokenization

Subword tokenization

Subword tokenization - баланс между представлением на уровне символов и представлением на уровне слов

На уровне символов

- Слишком длинные последовательности
- Теряется семантика, смысл

На уровне слов

- Проблема out-of-vocabulary words
- Слишком большой словарь

Subword tokenization

- Часто используемые слова рассматриваются как отдельные токены
- Редкие слова раскладываются на несколько осмысленных подслов

В результате

- Ограниченный размер словаря
- Осмысленные представления
- Способность обработать любое новое слово
- Один токенизатор для всех языков сразу

Byte Pair Encoding

- Берем большой корпус текстов
- Заранее определяем размер словаря (например, 50к)
- Начинаем с отдельных символов как токенов
- На каждой итерации сливаем два токена, которые имеют максимальную частоту совместной встречаемости
- Заканчиваем, когда достигнут размер словаря или максимальная частота равна 1

Byte Pair Encoding

AABABCABBAABAC

AA – 2
AB – 4 AB = D
BA – 3
BC – 1
CA – 1
BB – 1
AC – 1

ADDCDBADAC

AD – 2 AD = E
DD – 1
DC – 1
CD – 1
DB – 1
DA – 1
AC – 1

EDCDBEAC

Другие варианты

- WordPiece
- Unigram Language Model

В следующий раз

- Рекуррентные нейронные сети (RNN)
- LSTM, GRU
- Seq2seq models